


# Data-centric Machine Learning ops for autonomous driving

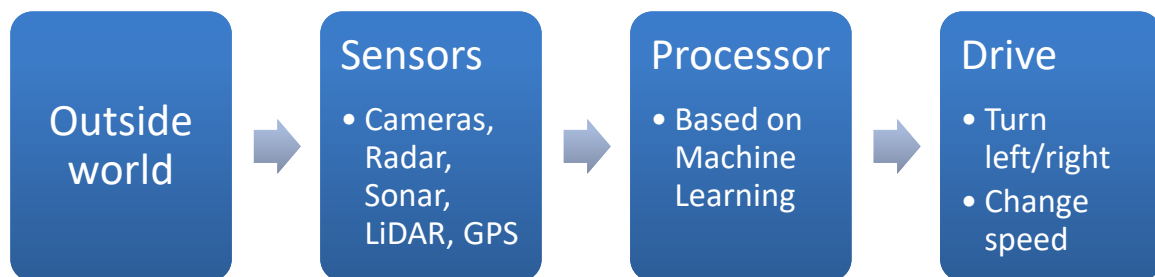
Supervisor	Miguel Drummond	<a href="mailto:mvd@av.it.pt">mvd@av.it.pt</a>
Colaboradores	João Gomes	<a href="mailto:j.gomes@ua.pt">j.gomes@ua.pt</a>
	Xavier Santos	<a href="mailto:xavier@ua.pt">xavier@ua.pt</a>
	Leandro Alexandrino	<a href="mailto:l.alexandrino@ua.pt">l.alexandrino@ua.pt</a>
	Petia Georgieva	<a href="mailto:petia@ua.pt">petia@ua.pt</a>
	Arnaldo Oliveira	<a href="mailto:arnaldo.oliveira@ua.pt">arnaldo.oliveira@ua.pt</a>
	Pedro Girão	<a href="mailto:Pedro.Girao@pt.bosch.com">Pedro.Girao@pt.bosch.com</a>
	Hadi Zahir	<a href="mailto:Hadi.Olyaei@pt.bosch.com">Hadi.Olyaei@pt.bosch.com</a>
	Bruno Faria	<a href="mailto:Bruno.Faria@pt.bosch.com">Bruno.Faria@pt.bosch.com</a>



**Palavras chave** deep learning, visão por computador, deteção de objetos em 3D, datasets sintéticos, GTA V

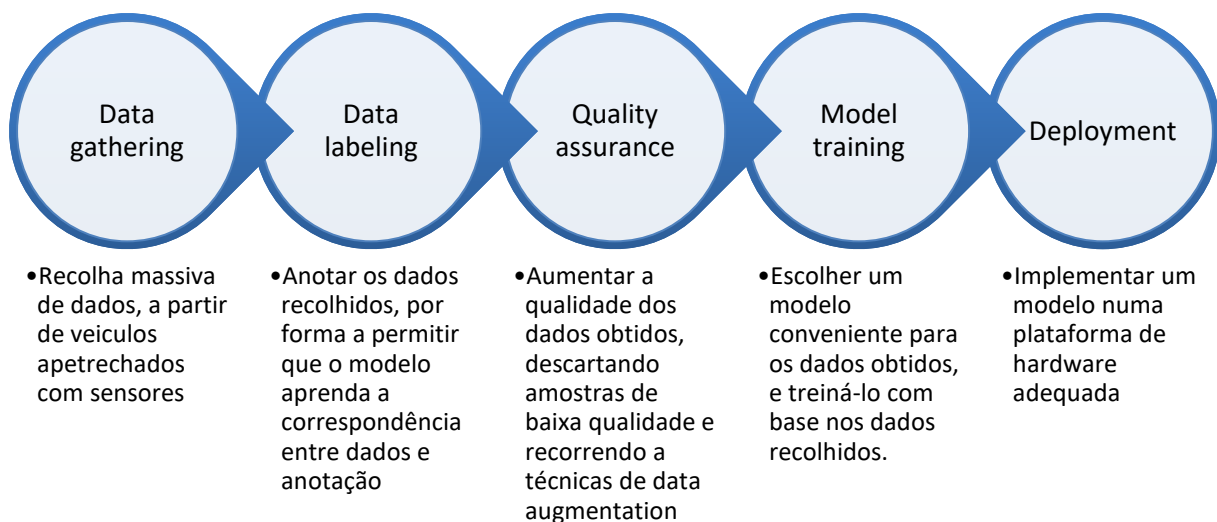
## Contexto

Embora o problema de ensinar um carro seja complexo de resolver, este pode ser descrito de forma simples de acordo com o diagrama seguinte.



Uma parte importante do processamento dos dados gerados pelos sensores é feito com recurso a Machine Learning. A qualidade do modelo de Machine Learning depende em grande parte da quantidade e qualidade de dados utilizados para aprendizagem. Desta forma, um bom processador será aquele que já tiver “percorrido” muitos quilómetros de estrada, diversos ambientes (cidade vs. autoestrada, dia vs. noite, etc.), ao longo de muitas horas.

O problema de ensinar um carro a conduzir sozinho resume-se então a iterar os seguintes passos:



## Objetivos

O objetivo deste trabalho é formar uma equipa capaz de desenvolver um sistema de Machine Learning o mais end-to-end possível, ou seja, uma equipa de [MLops](#), no contexto de condução autónoma, com foco nos dados (data-centric), ao invés de no modelo (model-centric).

Uma vez que um veículo autónomo incorpora vários sistemas de Machine Learning, torna-se crucial focar este projeto apenas num destes sistemas: identificação de objetos em 3D.

## Plano de trabalhos

A equipa será organizada em consonância com o diagrama apresentado na página anterior.



### Data gathering team: objects

- Esta equipa será responsável por obter dados (na forma de point clouds) de forma sintética, a partir de um mod construído sobre o jogo GTA V.
- Este mod está já bastante desenvolvido, e faz já labeling (segmentação semântica).
- Esta equipa será responsável por capturar point clouds apenas de objetos (isto é, 3D scans de carros).




### Data gathering team: scenes

- Esta equipa será responsável por capturar point clouds apenas de cenários (sem quaisquer objetos), por forma a capturar mapas (em 3D).



### Dataset generation team

- Esta equipa será responsável por construir um dataset de objetos + cenários a partir dos dados recolhidos.
- Esta equipa será responsável por garantir a qualidade dos dados capturados de três formas: removendo as amostras de má qualidade, recorrendo a estratégias de data augmentation, e particionando os dados em datasets de forma conveniente.



### Model team

- Esta equipa será responsável por escolher, otimizar e treinar modelos para reconhecimento de objetos 3D. Por uma questão de simplicidade, estes modelos serão compatíveis com a toolbox OpenPCDet.



### Deployment team (opcional)

- Esta equipa será responsável por encontrar soluções para implementar o modelo obtido numa FPGA evaluation board (Xilinx ZC706).



### Management team

- Esta equipa será responsável por gerir todas as equipas por forma a obter um desempenho acordado.
- Esta equipa será também responsável por toda a interação com clientes. Tal inclui construir a página web, desenvolver um template uniforme para apresentar resultados (por exemplo em pandas), e apresentar resultados.

Links explicativos: **Data team.** Mod GTA V descrito [aqui](#), [aqui](#) e [aqui](#). Data augmentation explicada [aqui](#); **Model team.** [OpenPCDet](#), [PointPillars](#); **Management team.** [Pandas](#), [Jupyter labs](#).

Considera-se que o trabalho estará concluído com total sucesso quando:

1. Demonstrarem que o modelo escolhido e treinado pela equipa atingiu um desempenho razoável.
2. Seja testada a seguinte premissa: é melhor ter poucos dados mas de elevada qualidade, do que ter muitos dados sem qualidade comprovada.

## Ferramentas

A equipa terá acesso a uma workstation com as seguintes características: INTEL CORE I9 10900K LGA1200, 128 GB DDR4 RAM, 2 TB SSD, GeForce RTX 3090 GPU, Ubuntu.

A deployment team terá acesso a uma Xilinx evaluation board ZC706.